Centro Escolar CEICAVS — Servicio Social
Sistema de Transcripción con Inteligencia Artificial
Documento explicativo del uso de IA: modelo, arquitectura y flujo del proceso
Proyecto: Sistema Escolar CEICAVS **Módulo:** Transcripción con IA **Modelos usados:** Whisper ONNX + Groq llama-3.3-70b + Gemini 2.0 flash
Responsable: Francisco Hernandez **Versión:** 1.0 **Fecha:** Abril 2025
Transcripción con IA
Integración de Inteligencia Artificial
CEICAVS — 2025

1. Visión General del Sistema

El módulo de transcripción de CEICAVS combina dos tecnologías de inteligencia artificial para ofrecer un flujo completo desde el audio de una reunión hasta un resumen estructurado:

1. **Transcripción del audio** — El modelo Whisper de OpenAI corre directamente en el navegador del usuario mediante Web Worker y modelos ONNX. No se envía el audio a ningún servidor externo.
2. **Generación del resumen** — El texto transcrito se envía al backend de CEICAVS, que lo procesa con un proveedor LLM (Groq como primario, Gemini como fallback) y devuelve un resumen estructurado.

2. Pipeline Completo del Sistema

Flujo de datos

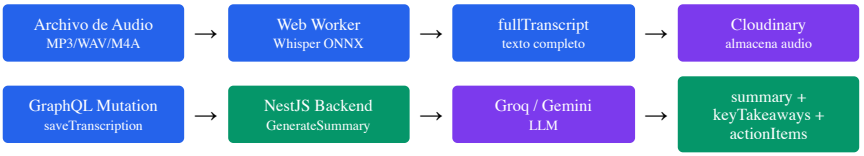

3. Componente 1: Transcripción en el Navegador

3.1 Tecnología utilizada

Atributo	Detalle
Librería	`@huggingface/transformers` v4.0.1 (Transformers.js)
Modelo primario	`onnx-community/whisper-small` — requiere WebGPU (Chrome 113+)
Modelo fallback	`onnx-community/whisper-base` — usa WASM en dispositivos sin WebGPU
Ejecución	Web Worker dedicado — no bloquea la interfaz de usuario
Archivos clave	`whisper.worker.ts`, `use-whisper-transcription.ts`
Privacidad	El audio nunca sale del dispositivo del usuario para la transcripción
Primera carga	~30s en la primera carga del modelo; en visitas posteriores se usa la caché del navegador

3.2 Ventajas de procesamiento en el navegador

- **Privacidad:** El contenido del audio nunca abandona el dispositivo durante la transcripción.
- **Sin costo por API:** No se usa ningún servicio de pago para la transcripción.
- **Sin latencia de red:** El procesamiento es local; sólo el texto resultante se transmite.
- **Compatibilidad:** Funciona con WebGPU (rápido) o WASM (compatible con navegadores más viejos).

3.3 Progreso en tiempo real

El Web Worker emite eventos de progreso que la interfaz escucha para mostrar una barra de avance. El proceso incluye las fases: carga del modelo → tokenización → inferencia → decodificación → completado.

4. Componente 2: Generación de Resúmenes con LLM

4.1 Proveedores de IA

Primario **Groq — `llama-3.3-70b-versatile`**

Servicio	Groq Cloud API (groq.com)
Modelo	Meta LLaMA 3.3 70B Versatile
Latencia promedio	< 5 segundos para transcripciones de 1,000 palabras
Activación	Siempre que no haya error de rate limit

Fallback **Google Gemini — `gemini-2.0-flash`**

Servicio	Google AI Studio / Gemini API
Modelo	Gemini 2.0 Flash

Activación automática	Cuando Groq devuelve HTTP 429 (rate limit excedido)
Implementación	`FallbackAIProvider` en `apps/api/src/modules/transcription/providers/`

4.2 Estructura de la respuesta

```
{
  "summary": "Resumen ejecutivo de la transcripción...",
  "keyTakeaways": [
    "Punto clave 1...",
    "Punto clave 2...",
    ...
  ],
  "actionItems": [
    "Elemento de acción 1...",
    "Elemento de acción 2...",
    ...
  ]
}
```

4.3 Manejo de transcripciones largas

Las transcripciones que superen los 15 KB son fragmentadas automáticamente por el backend. Cada fragmento se resume por separado y los resúmenes parciales se consolidan en un resumen final único. Esto evita exceder los límites de tokens de los modelos LLM.

5. Capturas del Sistema en Funcionamiento

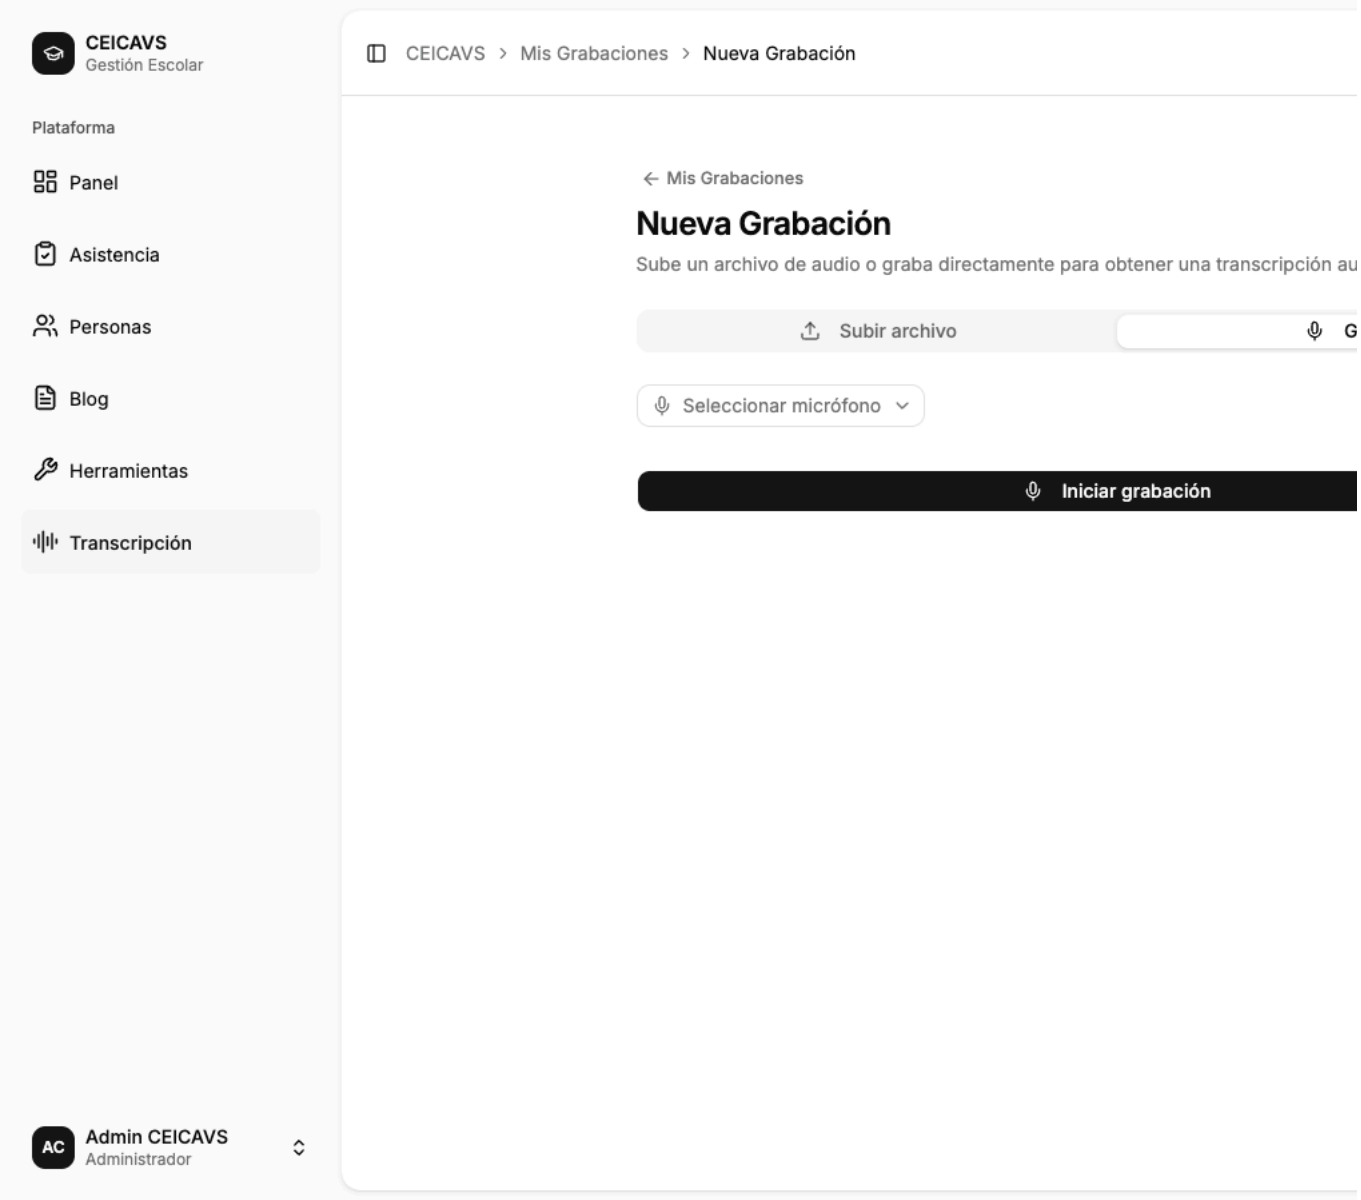

Pantalla inicial del módulo de transcripción

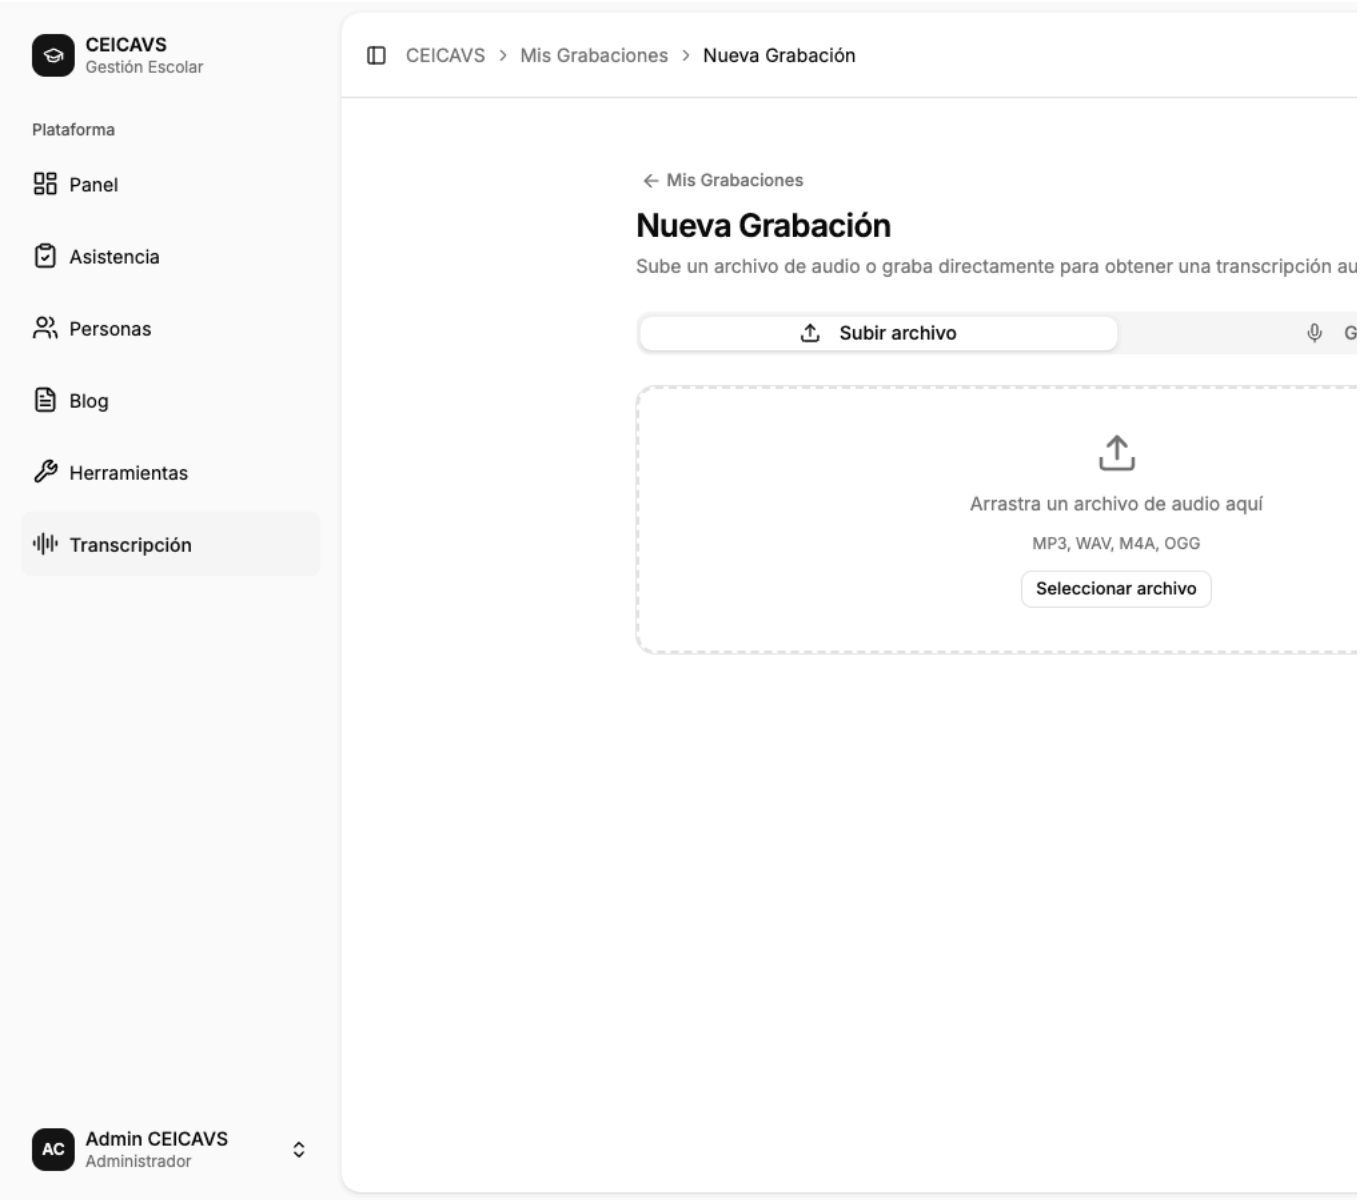

Selección de archivo de audio para transcribir

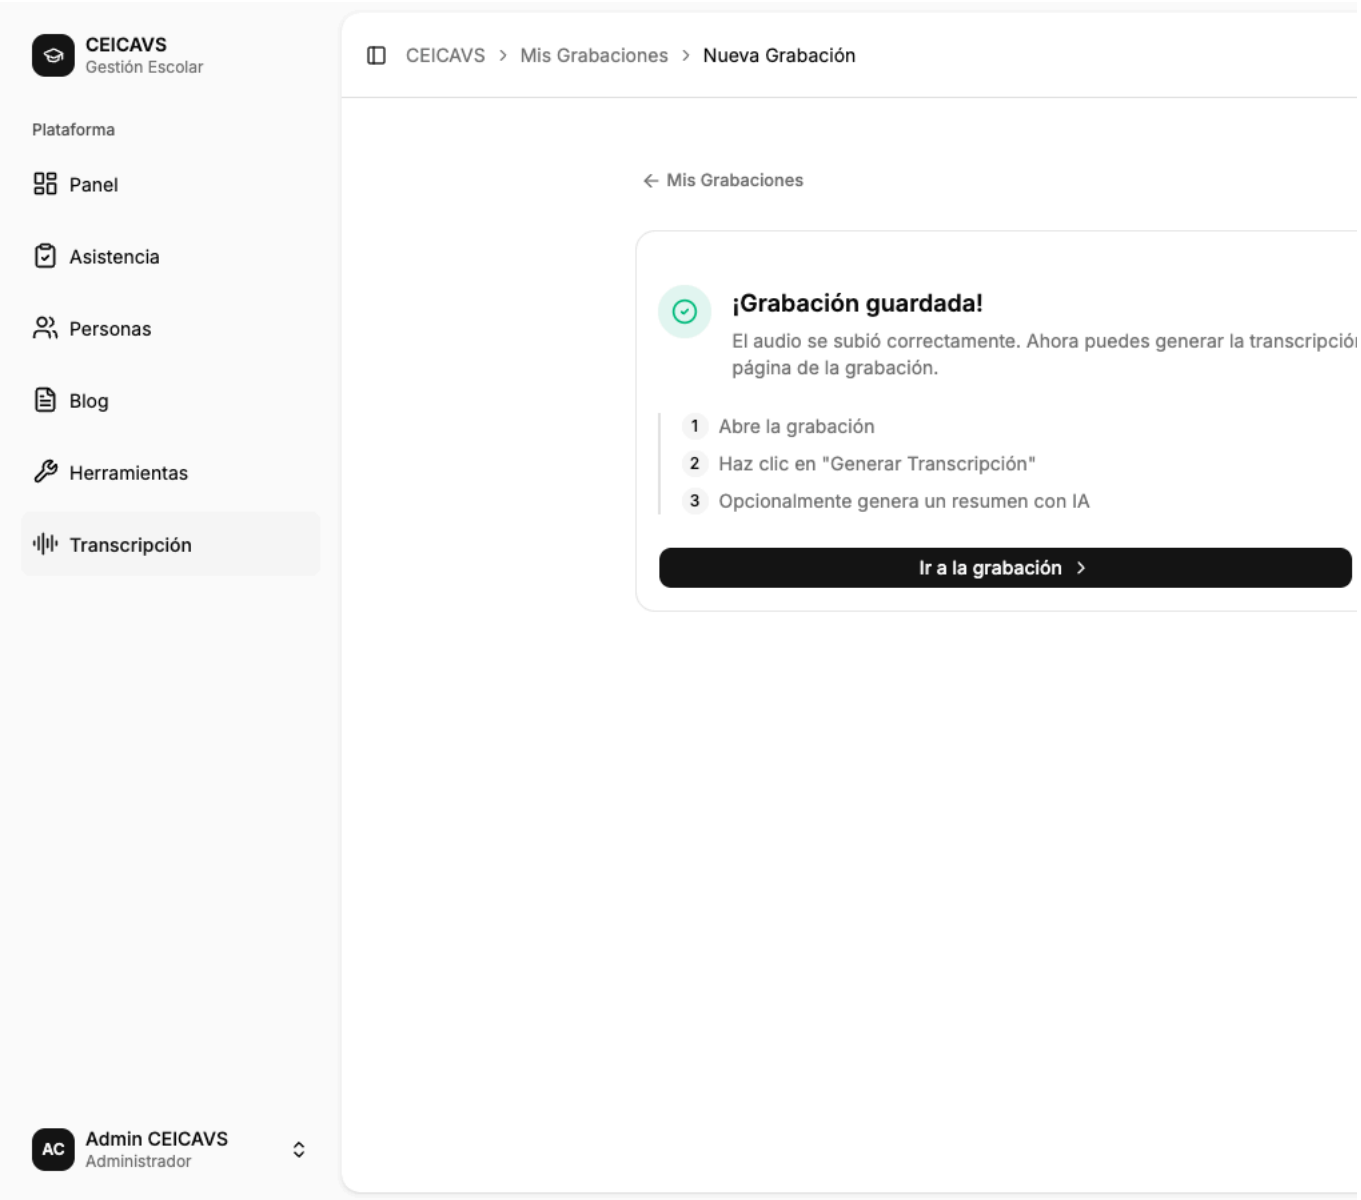

Archivo de audio seleccionado listo para procesar

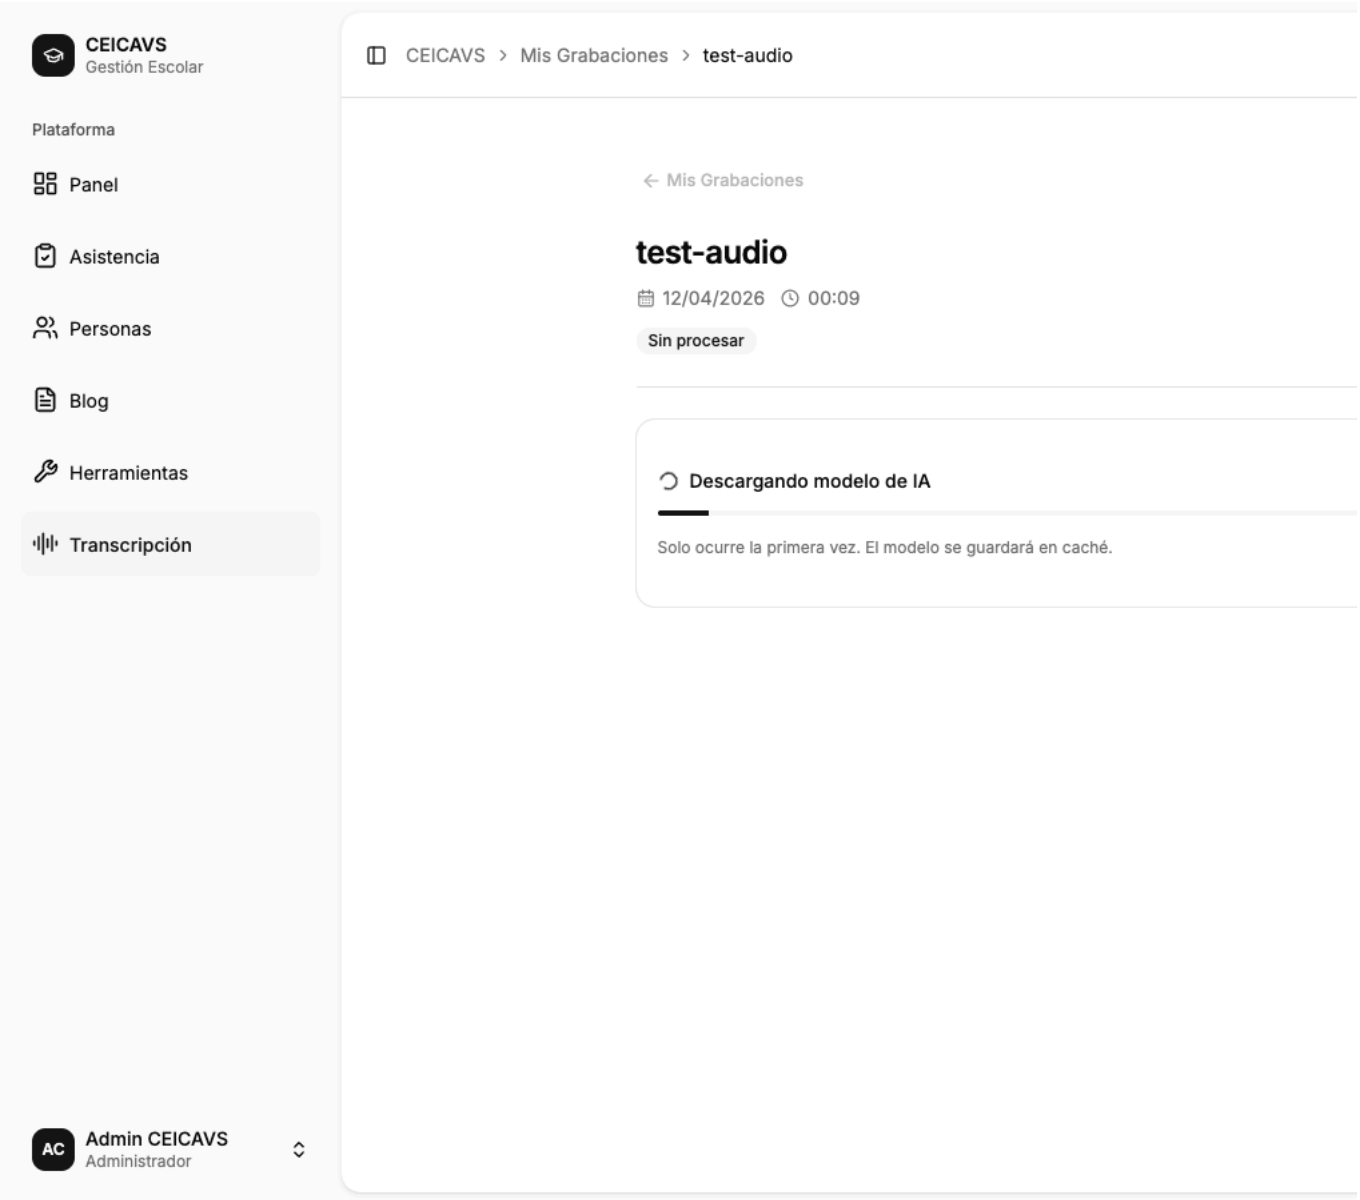

Transcripción en proceso en el navegador

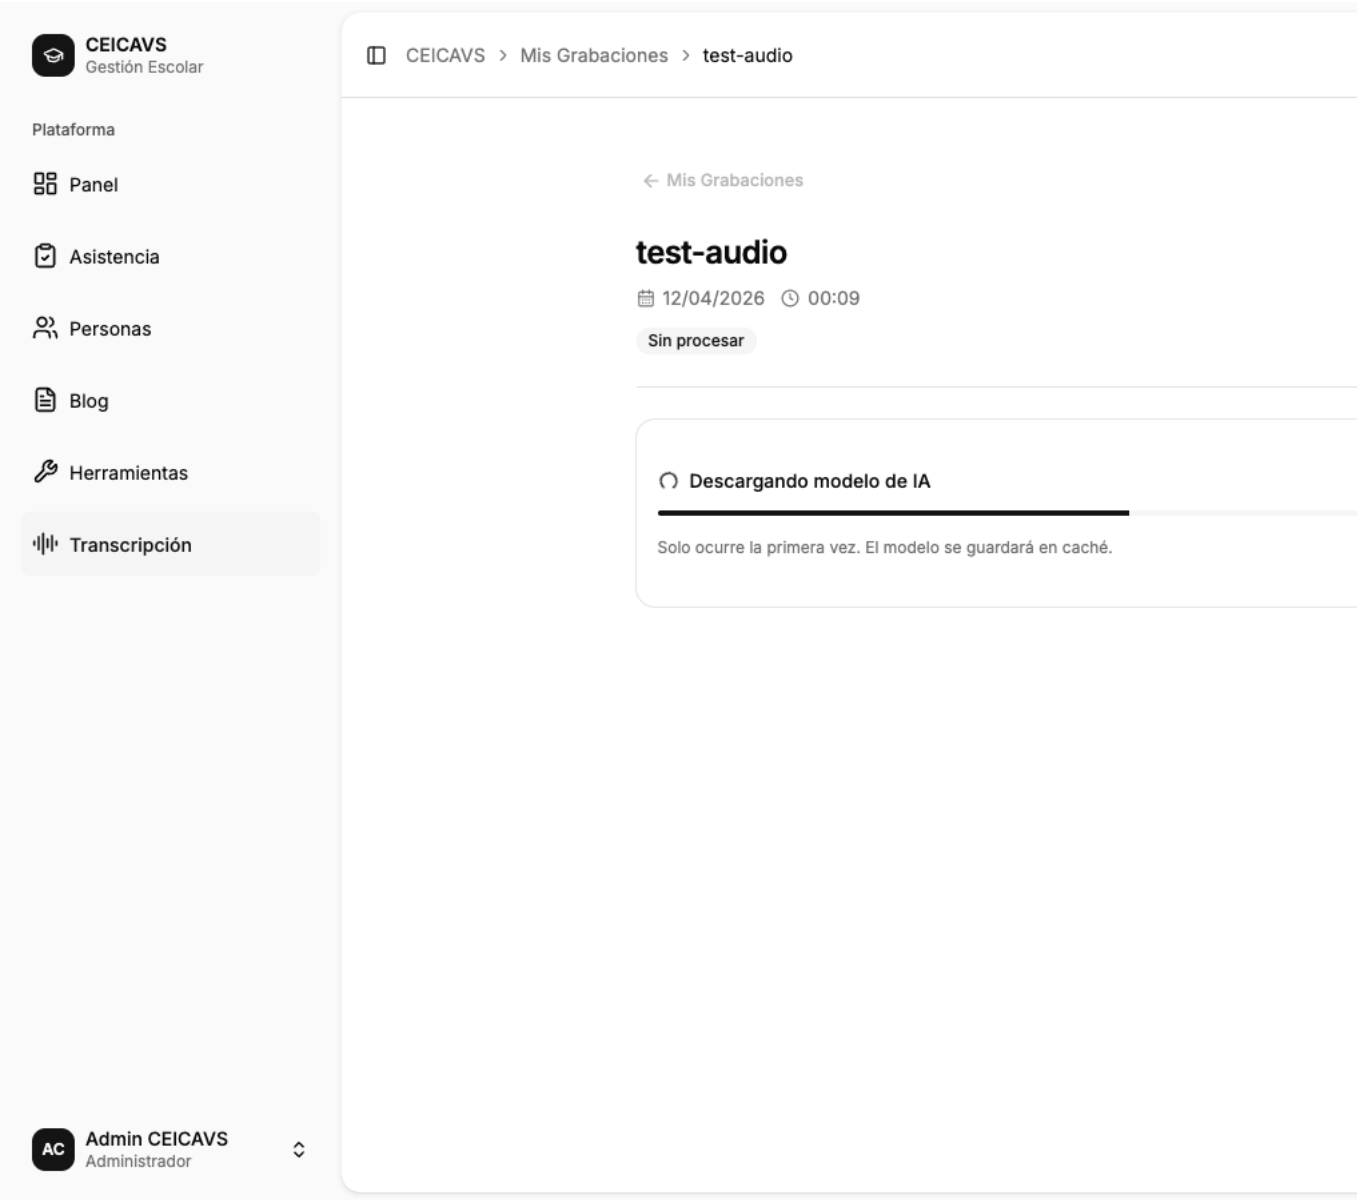

Barra de progreso de la transcripción en tiempo real

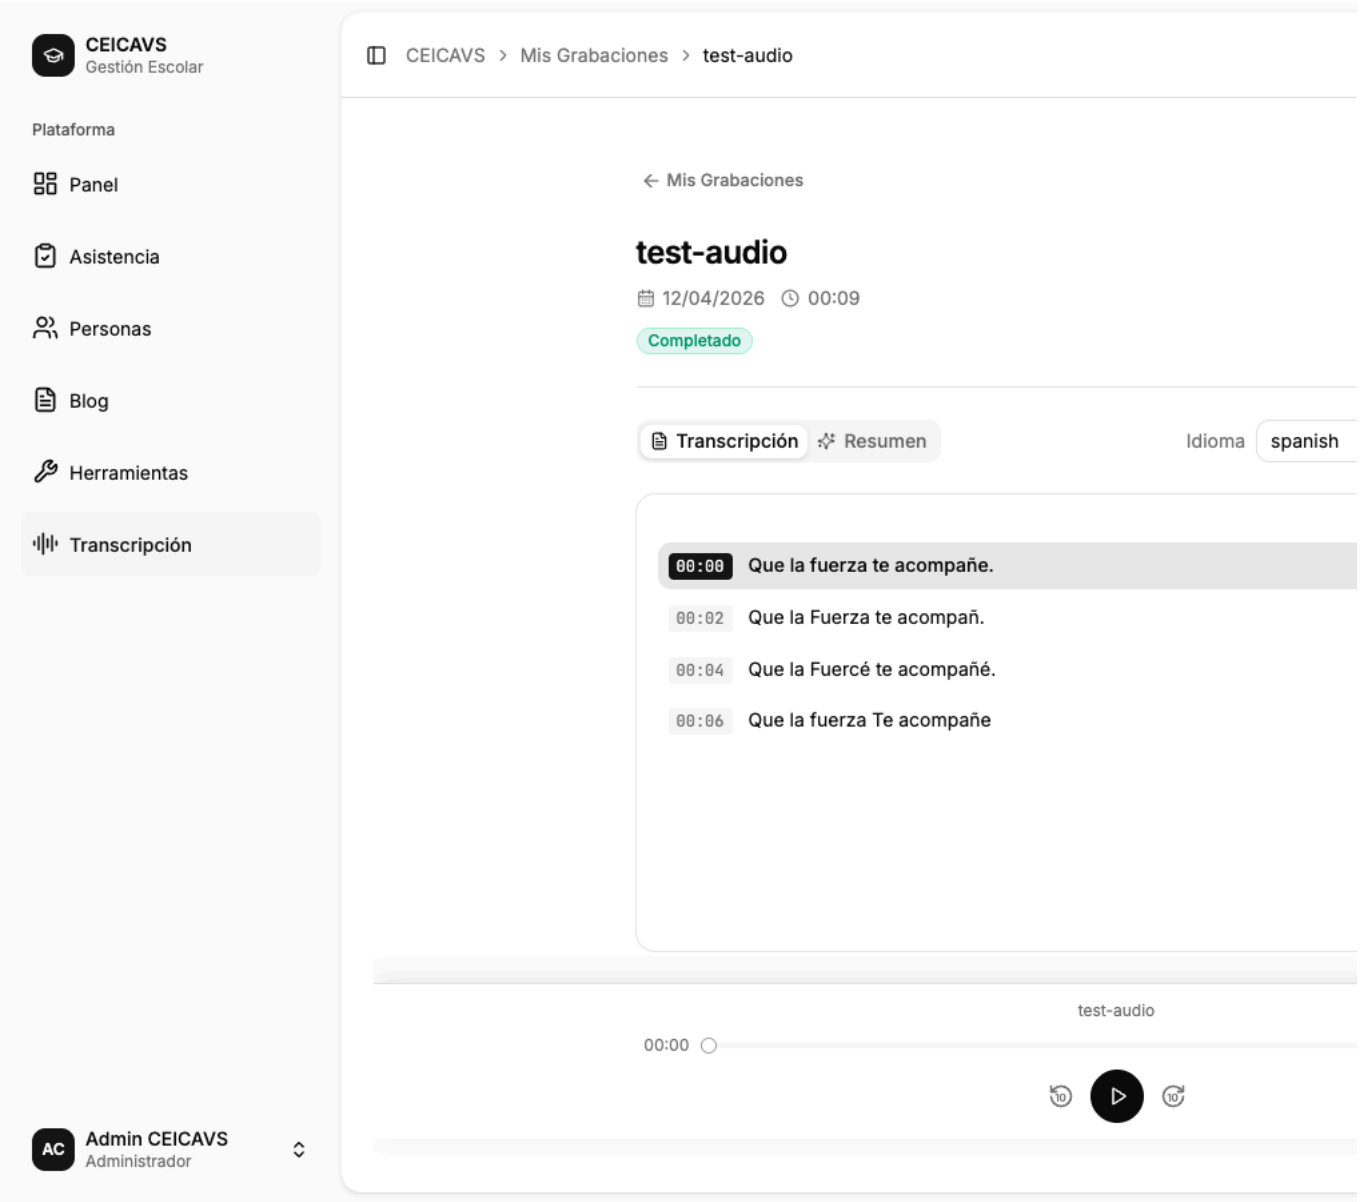

Fase final de la transcripción

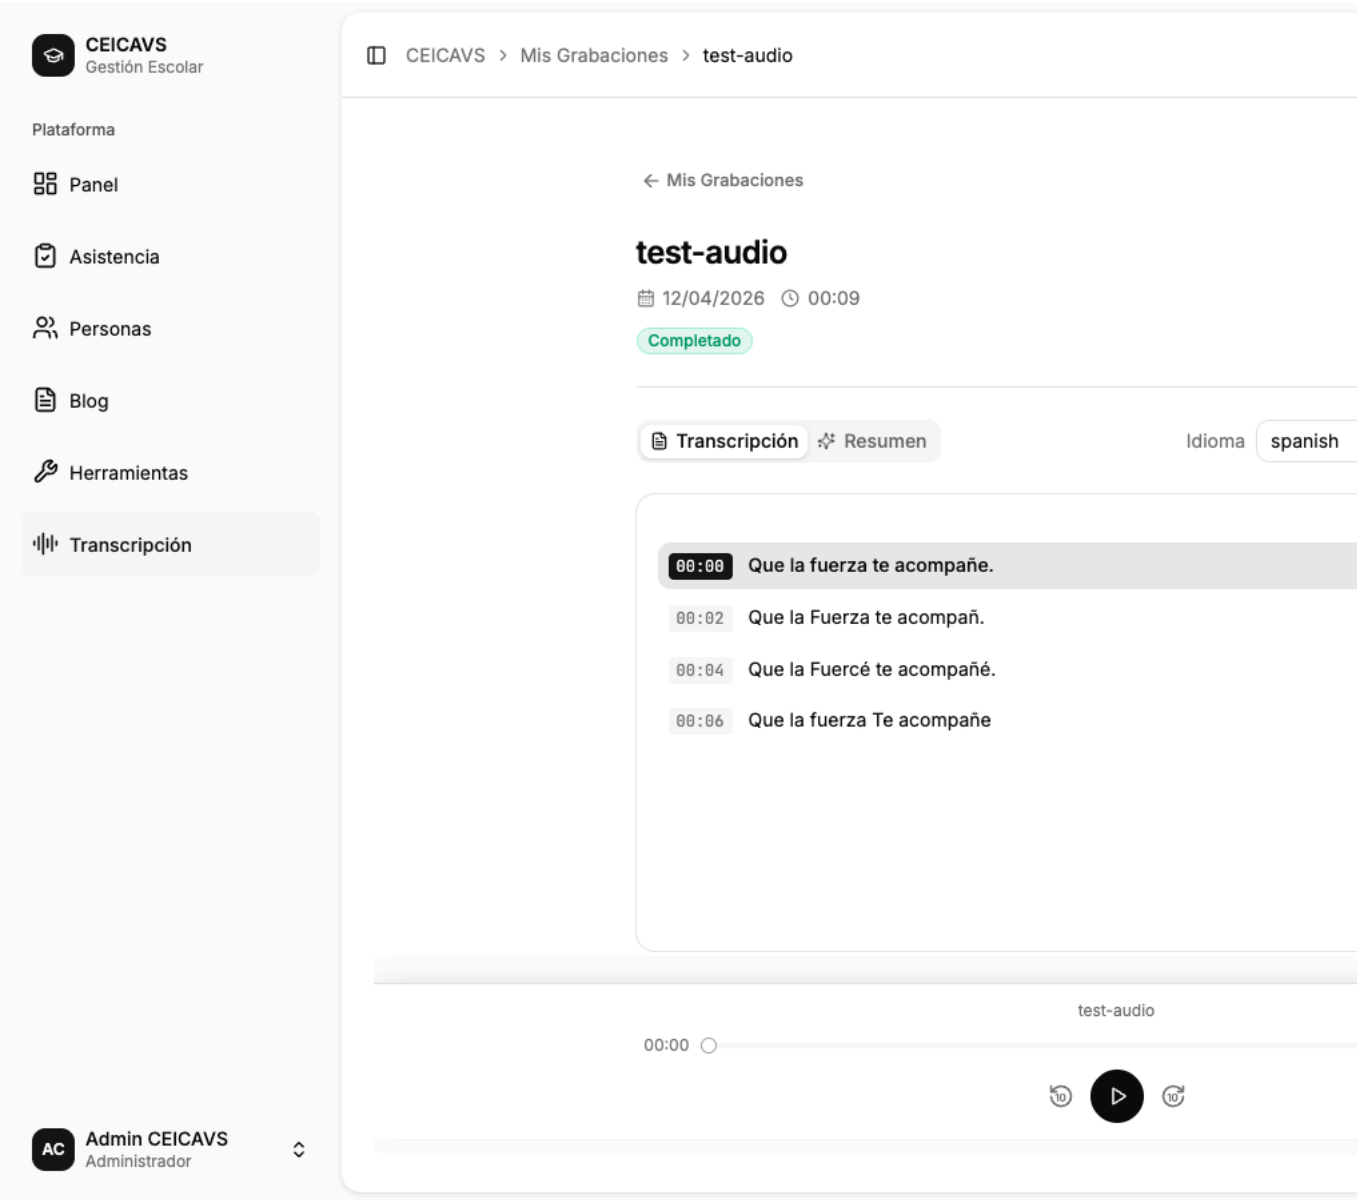

Transcripción completada lista para revisar

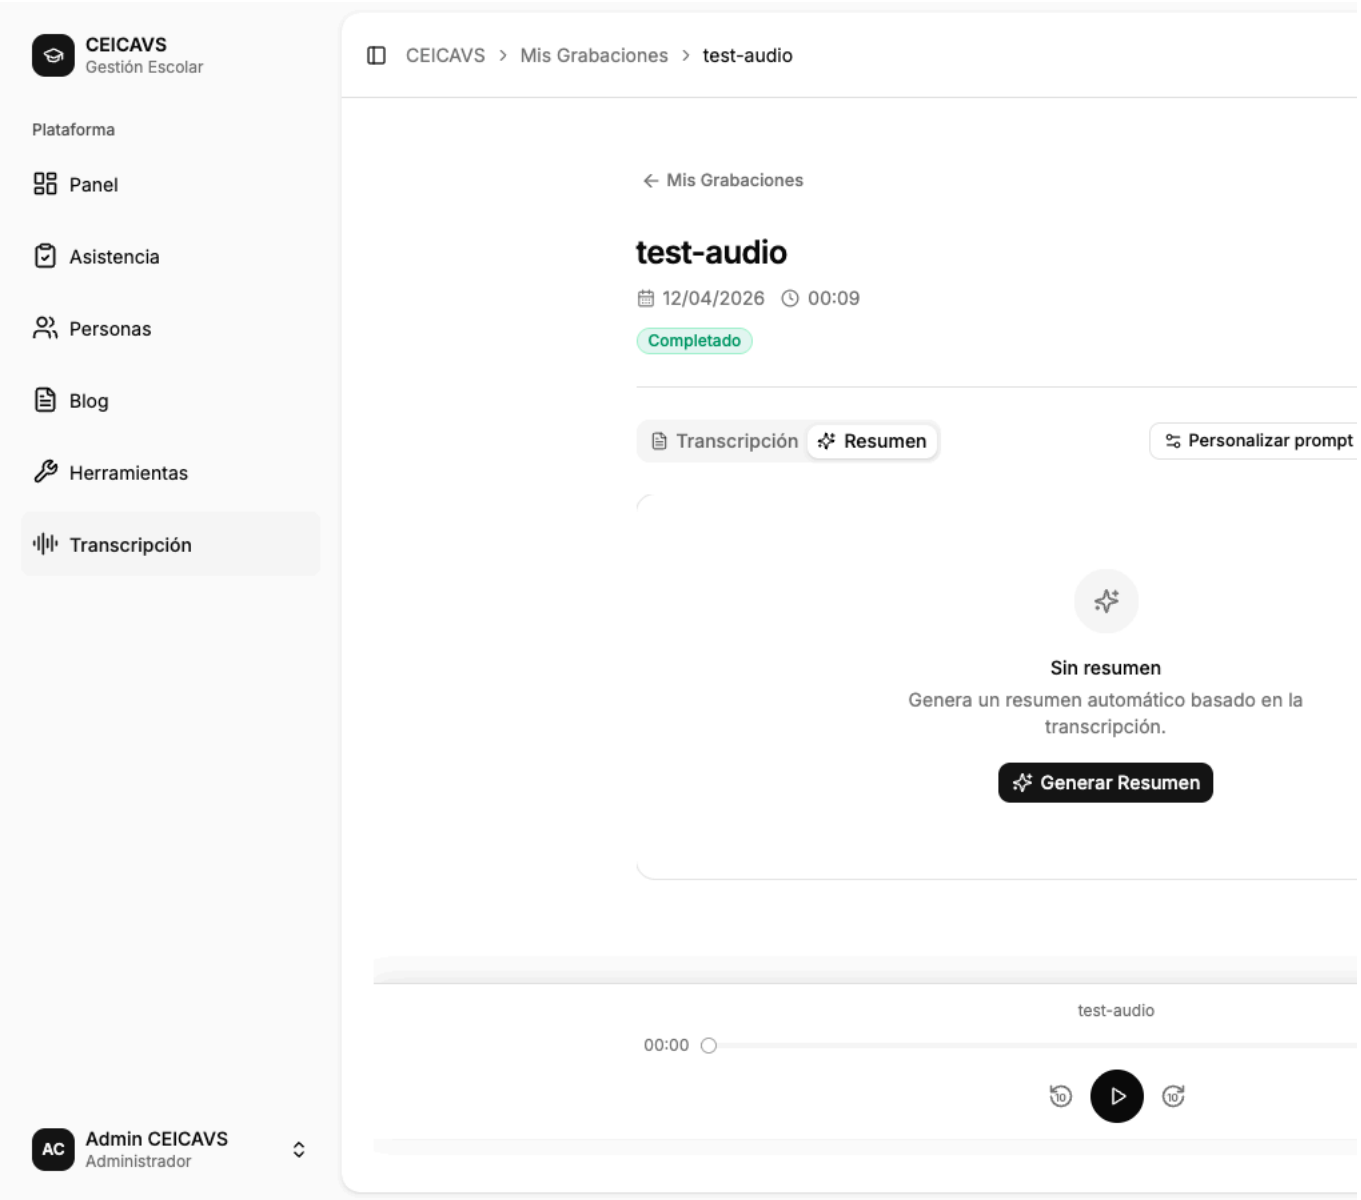

Pestaña de resumen antes de generarlo

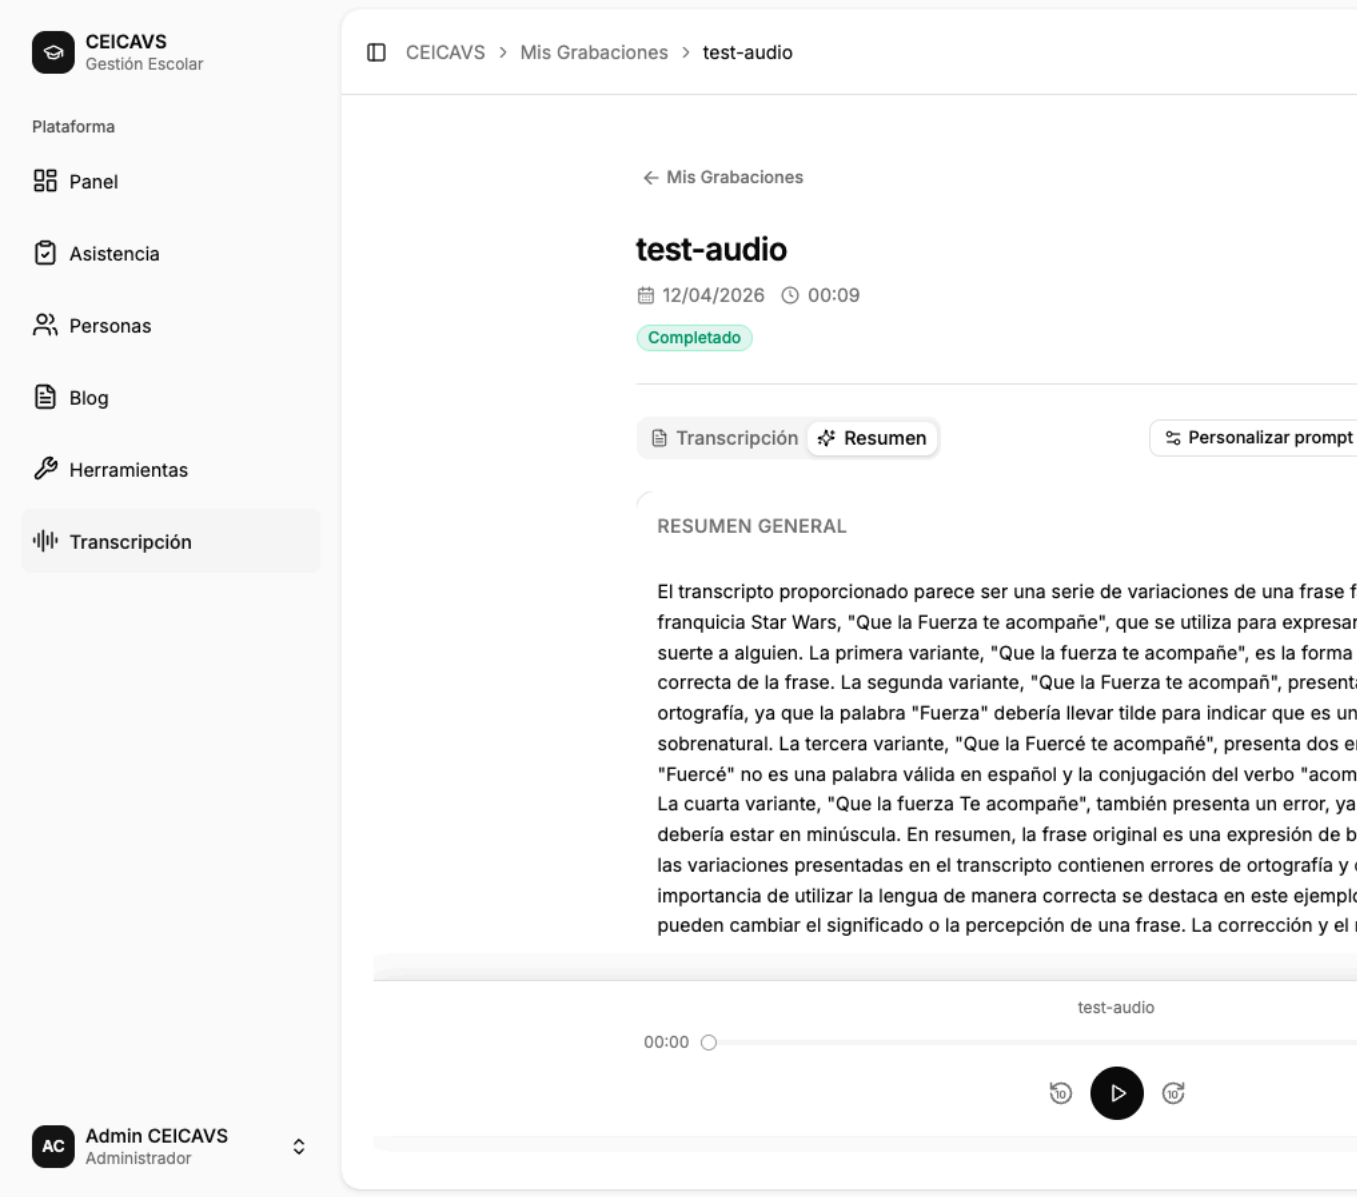

Generando resumen con LLM (Groq/Gemini)

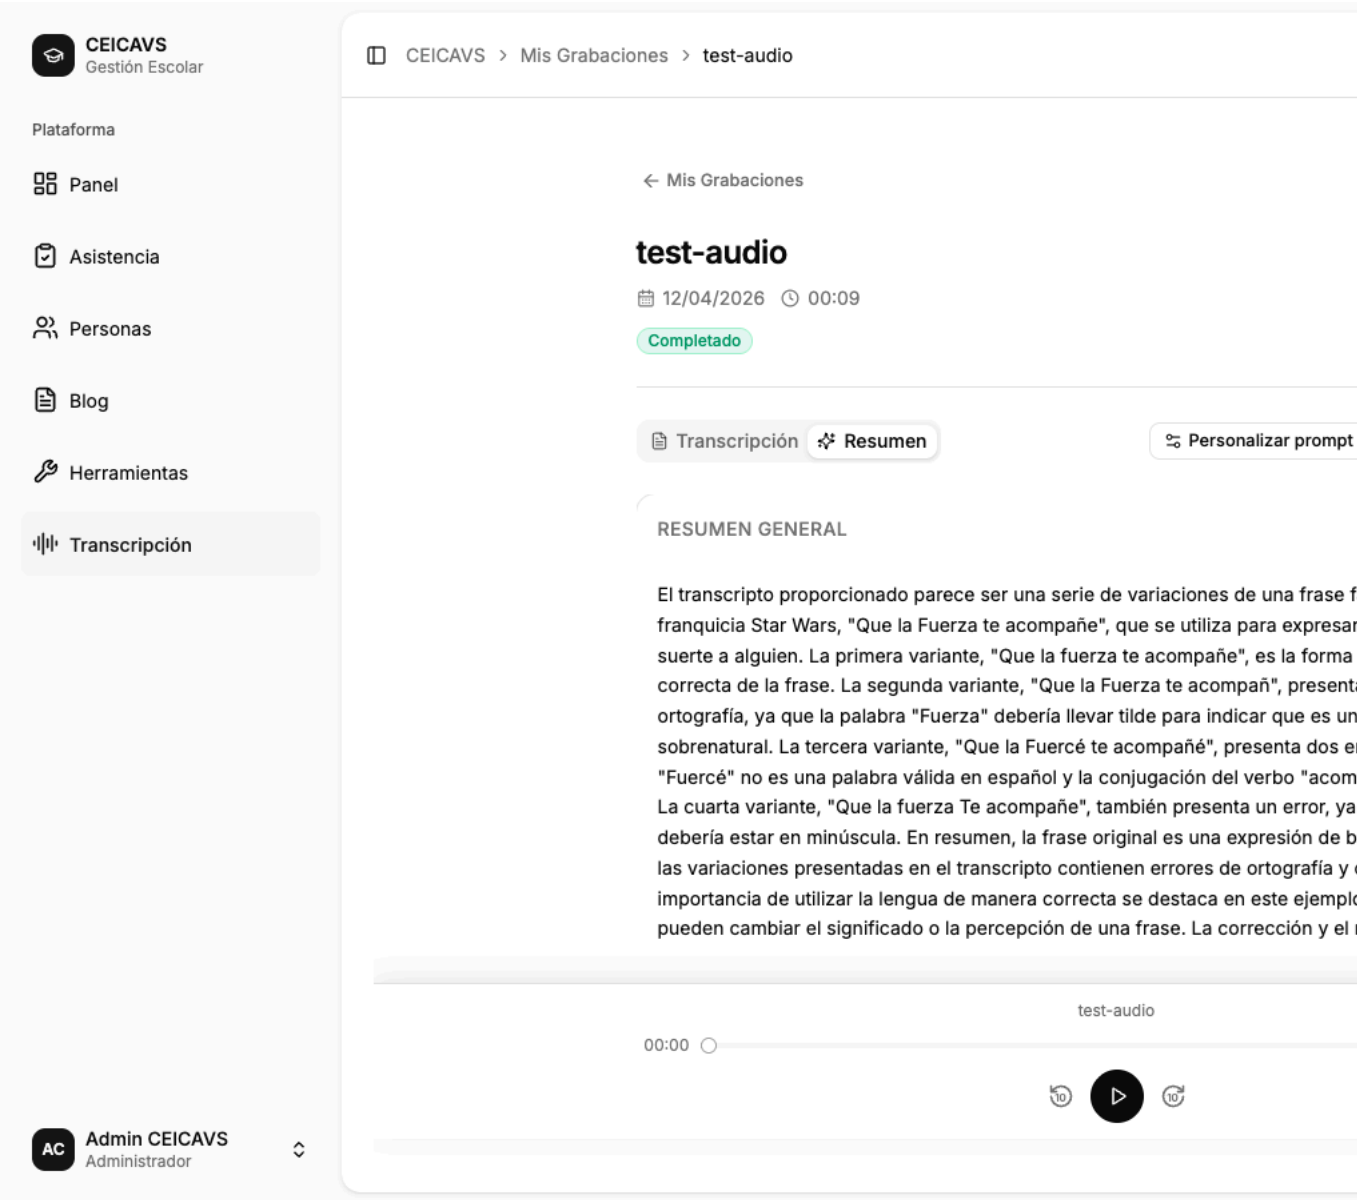

Resumen generado con puntos clave y elementos de acción

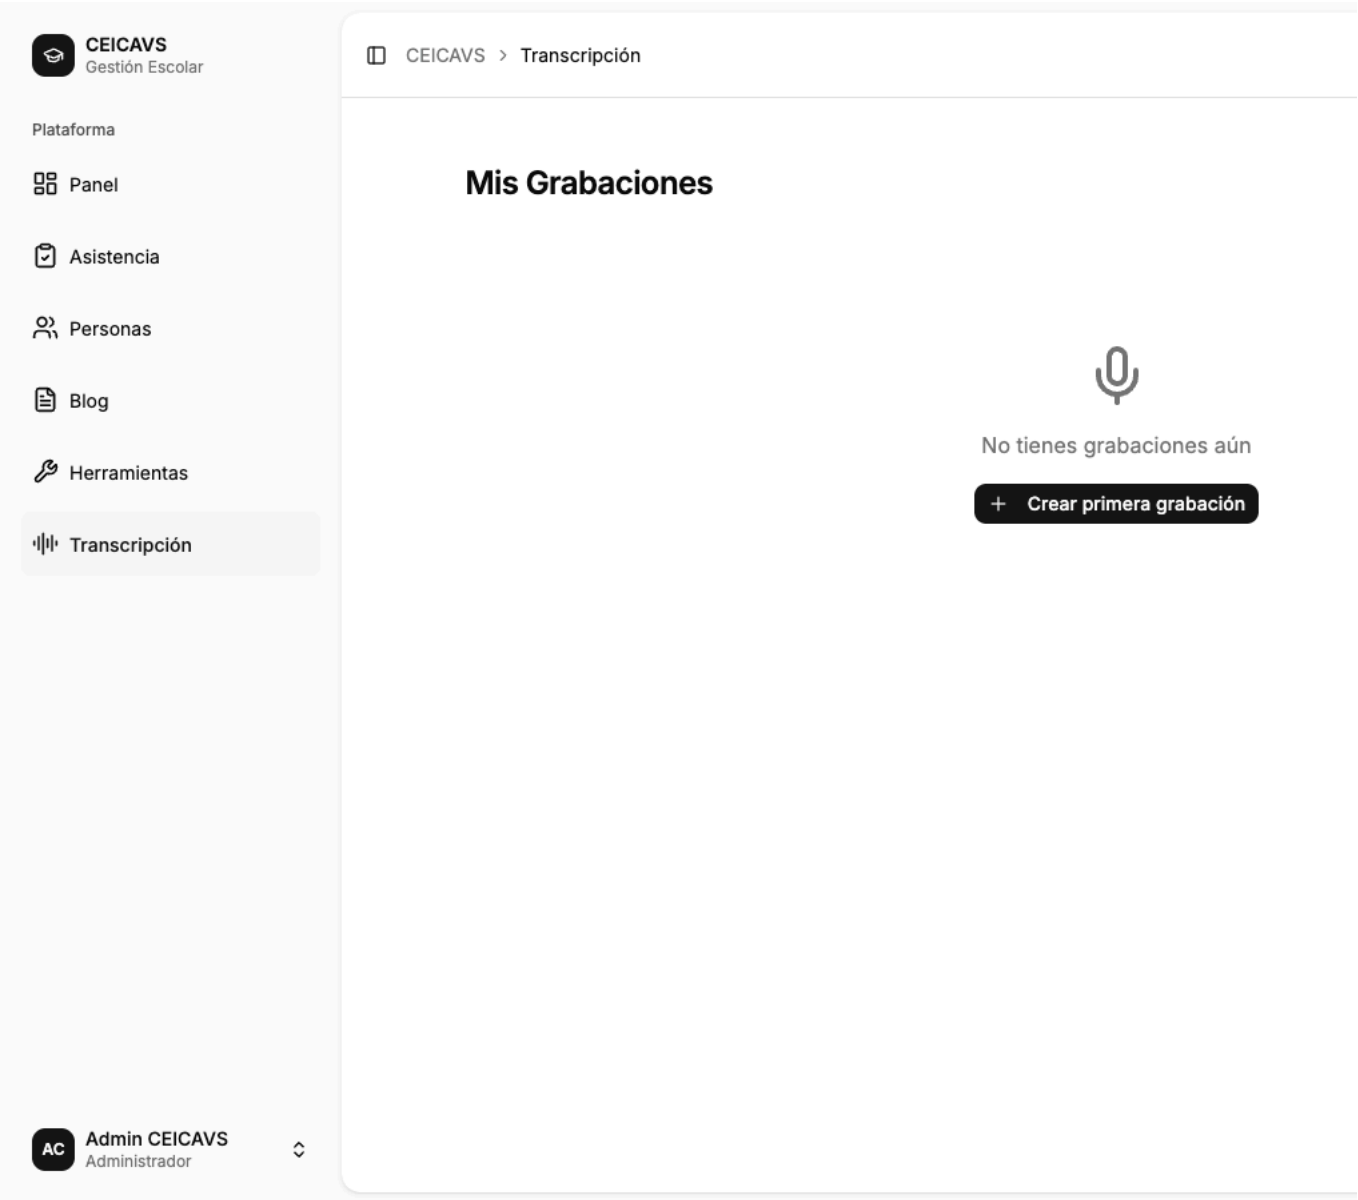

Lista de grabaciones del usuario

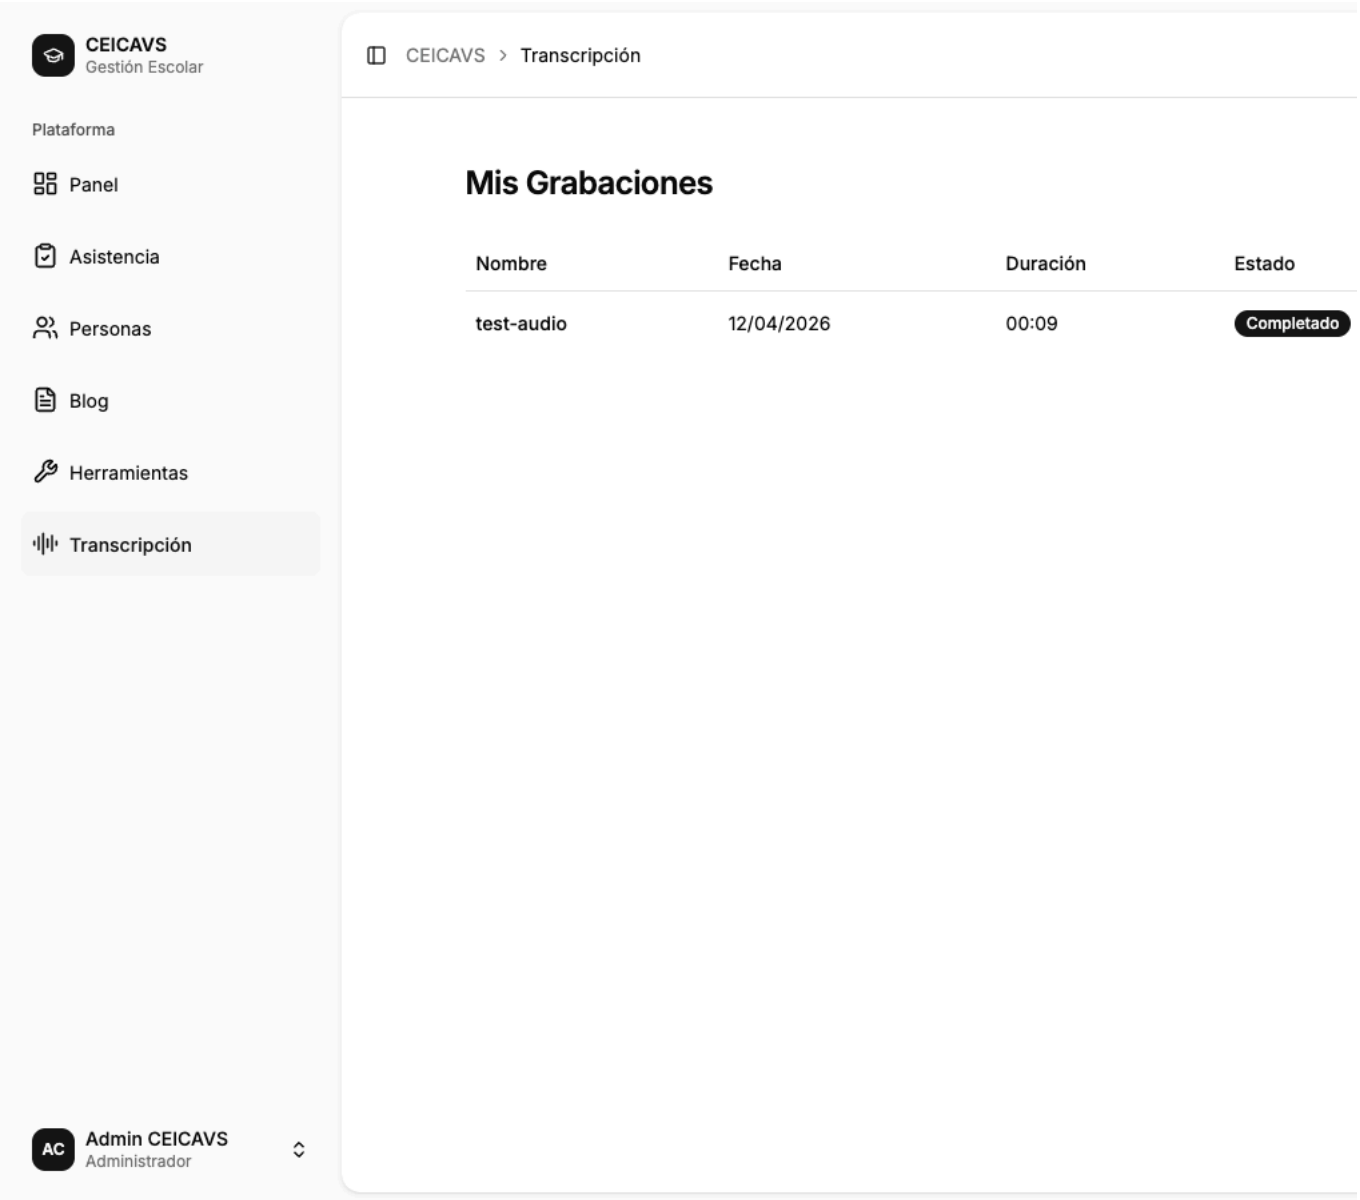

Lista con grabación transcrita completada